



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

参赛队号

队员姓名

1.
2.
3.

中国研究生创新实践系列大赛 “华为杯”第二十三届中国研究生 数学建模竞赛

题 目： 面向局部模态缺失的可追溯多模态情感预测模型

摘 要：

针对复杂场景中多模态情感识别存在的时间错位、局部信息缺失和结论难以回溯等问题，本文建立“统一表征—缺失感知融合—原材料证据回溯”的完整框架。模型同时输出负向、中性、正向极性与区间 $[-3, 3]$ 内的情感强度；训练、验证和预测严格使用同一套 text_bert 输入及同一 BERT 编码器，未把无标签附件用于调参。

对于问题一，本文对附件 1 的 100 条原始视频逐一解码，以 BERT 生成 50×768 文本表征，以 37 个声学低层描述量的均值和标准差形成 50×74 语音表征，并由颜色、纹理、光流和人脸几何形成 50×35 视觉表征。提出基于累计语音能量分位点的单调对齐方法，在每个样本中保留“词元位置—原视频秒数—帧号”映射。100 条样本均成功提取，标签构成为正向 57、负向 18、中性 25，压缩特征共 8.45 MB。

对于问题二，本文先以注意力掩码和三模态联合有效边界区分有效内容、区内疑似缺失与尾部填充，再构建含可学习缺失标记、时序 Transformer、可靠度先验和动态门控的多任务模型。连续区块缺失增强只作用于训练集；模型由验证集综合分选择。固定模型在验证集上的 Accuracy、Macro-F1、MAE、Pearson r 分别为 0.628、0.608、0.625、0.644，在未参与选择的测试集上分别为 0.624、0.584、0.668、0.658。对 10%–50% 连续缺失的压力测试中，增强模型平均综合分为 0.7039，高于无增强模型的 0.6988；其优势主要体现在文本缺失和高缺失率情形。由此得到附件 3 的 30 条一一对应预测：负向 12 条、中性 5 条、正向 13 条。

对于问题三，本文将动态门控与逐位置反事实遮蔽结合为模态作用度，并把关键文本、语音时间段和视频帧回映射至原视频。附件 4 的 20 条预测中，负向 8 条、中性 4 条、正向 8 条；平均作用度为文本 0.654、语音 0.166、视觉 0.181。由于附件 3、4 均无真实标签，本文只报告固定模型预测和可复核证据，不声称其真实准确率。全部结果均由独立脚本复现，并给出完整清单、图源数据和模型文件。

关键词： 多模态情感识别 局部模态缺失 动态可靠度门控 时序对齐 反事实解释

1 问题重述

1.1 问题背景

网络视频中的情感并不只由文字决定。说话内容、语调节奏、面部与场景变化共同影响判断，而且三类信息常因转写误差、静音、遮挡或采样过程而在局部时间片上不完整。CMU-MOSEI 将自然场景中的语言、语音和视觉信号组织为多模态情感分析基准^[1]；已有张量融合^[2]和跨模态 Transformer^[3]表明，多模态交互能补充单模态信息。然而，本题还要求处理连续局部缺失，并把预测依据映射回原始文字、时间和视频帧，因此仅给出一个分类器是不够的。

本文把任务抽象为两个相互约束的输出：三分类极性 $c \in \{0, 1, 2\}$ 与连续强度 $y \in [-3, 3]$ 。按题面， $y < 0$ 、 $y = 0$ 、 $y > 0$ 分别对应负向、中性、正向，三分类编码依次为 0、1、2。建模还必须满足三条数据边界：附件 1 的 100 条视频只用于问题一；附件 2 用于训练、验证与固定模型测试；附件 3、4 没有真实情感标签，不能用于选模或声称真实准确率。

1.2 任务重述

需要依次完成以下三项工作。

- 任务 1.** 对附件 1 的 100 条原始视频提取文本、语音和视觉时序特征，给出逐样本特征清单，并保留特征位置到原视频秒数和帧号的可逆追踪关系。
- 任务 2.** 基于附件 2 建立能处理局部连续缺失的多模态情感模型，在验证集上确定模型与阈值，在固定测试集上报告 Accuracy、Macro-F1、MAE 和 Pearson 相关系数，并对附件 3 的 30 个文件逐一预测。
- 任务 3.** 复用问题二的固定模型分析附件 4 的 20 条视频，量化文字、语音和视觉对每条结论的作用，输出可以回到原材料核对的关键文字、语音时段和视频帧。

1.3 本文工作范围

本文不引入任何外部情感标注数据。预训练 BERT 仅作为允许的通用表征工具；附件 2 独有的 50×768 text 数组不进入模型，以避免训练、验证和预测阶段文本支路不一致。所有无标签预测均保留文件名映射，结论仅表述为“固定模型输出”。

2 问题分析

2.1 输入审计与主要难点

首先对实际文件逐项读取而非沿用历史说明。审计结果见表 2.1。附件 2 的索引层级为“划分—模态—样本”；附件 3 的单个文件没有内部 id，必须以文件名作为主键；附件 3 的 text_bert 虽存为浮点型，但全部有限且为整数值，故在送入 BERT 前无损转换为 int64。附件 2 的 4,850 个分类标签与回归标签的符号映射全部一致。

表 2.1 输入数据审计

数据	训练	验证	测试/预测	标签	关键字段
附件 1	—	—	100	有	视频、转写、标签页
附件 2	3395	728	727	有	text_bert/audio/vision/id
附件 3	—	—	30	无	文件名、text_bert/audio/vision
附件 4	—	—	20	无	原视频、转写、对齐特征

数据诊断还揭示了不能直接把“全零”解释为缺失的原因：附件 2 训练集的语音和视觉第 0 步在 3,395 条样本中均为全零，这是统一出现的结构位置；而内容区内部全零只出

现在 4 条语音样本和 421 条视觉样本中。与此同时，3,142 条训练样本的旧 text 数组在文本掩码尾部仍有非零向量。因此，零值与有效性必须结合 BERT attention mask、联合时间边界和所在位置判断，不能由单一数值现象反推其物理成因。图 2.1 展示标签、长度和零位置诊断。




图 2.1 数据结构与诊断

2.2 分问题分析

问题一的核心是“可追踪对齐”。原始视频、转写和标签虽能建立一一对应，但转写没有逐词时间戳。若简单按第几个特征位置等同于第几秒，问题三将无法给出可信证据。本文以累计语音能量构造单调时间边界，再在同一边界内汇聚语音和视频特征，并保存原始帧率下的帧区间。

问题二的核心是“局部缺失而非整模态缺失”。现有缺失模态研究常处理某个模态整体不可用^[4,5]，而题目中的缺失可发生在前段、中段或后段的连续局部区间。本文显式拆分内容时间线与各模态观测掩码，用可学习缺失标记保留时间位置，再把观测比例作为门控先验。训练阶段只在有效内容内部随机遮蔽连续区块，避免把尾部填充当作训练缺失。

问题三的核心是“作用程度与证据位置同时给出”。单看门控权重可能高估模型的自陈重要性，单看遮蔽变化又会忽略模型原有的可靠度分配。本文融合二者，并以逐位置反事实扰动定位关键窗口。局部解释遵循模型无关解释“比较预测前后变化”的思想^[6]，但不以代理模型替代原模型。

2.3 总体技术路线

三问共享同一文本编码和时间映射，整体路线如图 2.2。其中附件 3、4 只经过最右侧固定模型推理路径，不回流至训练或模型选择。




图 2.2 总体技术路线

本文的主要设计是：统一 BERT 文本支路；联合边界下的三类掩码；可靠度先验动态门控；以及贯穿三问的“词元—时间—帧”证据链。

3 模型假设

为使模型可计算，同时避免把未核实事实写成结论，作如下假设。

- A1.** 题目给出的转写在句子层面与相应视频片段匹配，但不保证每个片段都能对齐：实测 100 条中 78 条可获得词级时间，且转写不从 0 时刻开始（首词起始时刻中位 0.49 s）、词间存在真实停顿（最大静音段中位 0.37 s）。文音不符的样本按扣留规则处理，其样本级标签对应关系仍成立。
- A2.** BERT attention mask 能可靠标识文本结构边界；在联合有效内容区内，某模态的全零行只记为“未观测或可疑”，不假设其必然由采集缺失造成。
- A3.** 官方转写的词序与音频中的实际发音顺序一致，因此可用带发音词典的强制对齐定位其时间。该假设不要求转写与音频逐字相同：强制对齐允许插入与删除，口语简化或局部改词只影响对应词的置信度，不破坏单调顺序。
- A4.** 强制对齐的输出是自动结果，不是人工核验的真值：TextGrid 与官方词序列的词汇一致性仅在 69/80 条上完全成立，其余经词形归并后对齐。逐词时间一律以“暂定”层级记录，不作为精确时间引用。
- A5.** 附件 2 的训练、验证和测试划分来自同一任务分布；验证集可用于模型选择，测试集只用于最终一次固定模型评估。
- A6.** 情感强度的符号规则严格成立：负向 $y < 0$ 、中性 $y = 0$ 、正向 $y > 0$ 。对分类头与回归头发生边界冲突的输出采用最小幅度符号投影。
- A7.** 附件 3、4 没有真实标签。因此其预测置信度只代表模型后验集中程度，不能解释为样本真实正确概率。

4 符号说明

表 4.2 主要符号

符号	含义
i, t, m	样本、时间位置和模态索引， $m \in \{T, A, V\}$ 分别表示文本、语音、视觉
$L = 50$	统一序列长度
$\mathbf{x}_{it}^m$	样本 i 在位置 t 的模态 m 输入向量
u_{it}	是否属于有效内容时间线的布尔量
o_{it}^m	在有效时间线上模态 m 是否观测到的布尔量
ρ_i^m	模态观测可靠度，即观测位置占有效位置的比例
$\mathbf{h}_i^m$	模态时序编码并注意力汇聚后的表示
g_i^m	动态融合门控权重，满足 $\sum_m g_i^m = 1$
$\hat{p}_{ik}$	样本 i 属于类别 k 的预测概率
$\hat{y}_i$	情感强度预测，范围为 $[-3, 3]$
D_i^m	整体移除模态 m 后的反事实输出距离
R_i^m	最终模态作用程度
s_{it}, e_{it}	词元位置对应的原视频起止秒数
f_{it}^s, f_{it}^e	词元位置对应的原视频起止帧号

5 问题一：可追溯时序特征提取

5.1 样本对应与预处理

按附件 1 当前文件建立样本主键 `video_id/clip_id`。实际读取到 100 条视频和标签页 100 行记录，二者一一对应，无漏样、重样或无标签视频。标签页实际有 5 列，故不采用历史说明中的旧列数和本机路径。附件 1 与附件 2 的标识有 18 条交叠，其中训练集 11 条、测试集 7 条；本文只把这 100 条用于问题一的特征提取，未追加到问题二训练集。

视频先由 FFmpeg 解复用为原帧序列和 16 kHz 单声道波形。文本统一使用 bert-base-uncased 的词表与分词规则^[7]，模型版本由缓存元数据锁定到提交号，保证问题一与问题二的文本定义一致。

5.2 官方文本的 MFA 强制对齐

题目不提供逐词时间戳，却要求时序组织可核验，且问题三的关键证据须指回原始语音时段。一种直接做法是先做语音识别再取其词级时间，但这对本题不成立：识别文本与官方文本并不一致。以样本 `-3g5yACwYnA/13` 为例，声学模型对该段音频的识别结果为

OR EARLY SPRING SOME MANSERS TO THE TABLE

而官方文本为 `or at least bring some answers to the table`，其中 `at least`、`bring`、`answers` 三处均被识别错，且恰好落在情感语义上。若采用识别文本，既违反“以官方文本为准”，也会污染文本特征。

因此本文不做识别，改做强制对齐：只把官方词序列交给声学模型，让它回答每个词“在什么时候说的”。设声学模型在帧 t 上输出字符后验 $p(z_t | \mathbf{x}_t)$ ，词表 $\mathcal{V} = \{A, \dots, Z, ', -, \}$ ，其中 $-$ 为 CTC 空白、 $|$ 为词边界。把第 i 条样本的官方词序列按词间插入 $|$ 拼成字符序列 $\mathbf{c}_i$ ，对齐即求最大后验路径

$$\pi^* = \arg \max_{\pi \in \mathcal{B}^{-1}(\mathbf{c}_i)} \sum_{t=1}^T \log p(z_t = \pi_t | \mathbf{x}_t), \quad (5.1)$$

$\mathcal{B}$ 为 CTC 的多对一映射。字符级词表使专有名词等未登录词无需发音词典即可对齐。

该对齐采用 Kaldi 的 MFA 3.3.8 完成，声学模型为 `english_us_arpav3.0.0`、发音词典为同版本 `.dict`，命令为

```
mfa align --single_speaker --no_final_clean --num_jobs 4
```

在 80 条候选片段上耗时 107.167 s，输出 80 个 TextGrid。MFA 只参与定位，不产生任何进入特征的文字，官方文本始终是唯一的文本来源。若 MFA 不可用，本文另备一套 `wav2vec2` 字符级 CTC 对齐作为回退，规则与式 (5.1) 相同。

5.3 识别筛查与已知文音不符样本

在 MFA 之前先对全部 100 条片段独立做一次语音识别筛查，作用是发现官方转写与音频可能不符的样本，而不是决定是否对齐：筛查通过与否都不改变输入。筛查结果为通过 77 条、疑似不匹配 16 条、待复核 5 条、无语音 2 条。筛查命中的样本与已知问题清单高度重合，另有 2 条被独立判定为全程无语音。

据此，20 条本地已知的文音不符样本不进入 MFA 候选；MFA 完成后又有 2 条因对齐质量问题被扣留。最终 78 条获得词级时间，22 条降级为样本级。对降级样本，本文不给出任何词级音视频特征（详见 5.5 节），因为给一段与音频不对应的文本强行定位，得到的时间没有意义。

5.4 词窗聚合与 50 词槽网格

题目要求的输出是三模态在同一时间轴上的对齐特征。本文把**每一个时间片定义为一个官方词**，而不是一个 BERT 词元：词是转写与语音共同拥有的最小单位，而 BERT 会把 **They've** 切成 **they**、**'**、**ve** 三个词元，按词元切片会让一个词的时间窗被割裂。固定长度取 $L = 50$ ，即每个样本保留前 50 个官方词，不足 50 词在末尾补零。

文本支路。词级 768 维由该词覆盖的 BERT 词元隐状态**均值池化**得到。这里有一个必须处理的细节：词的个数与 BERT 词元个数并不相等（ $L = 50$ 个词可对应 80 个以上的词元），若按 50 词元截断编码，长样本的尾部词就取不到特征。本文以长度 128 编码，再由 MFA 词表提供的**字符区间**把词元归到所属词，因此长样本的全部 50 个词槽都有文本特征。

语音与视觉支路。两条支路都在 MFA 给出的词窗 $[s_{it}, e_{it}]$ 内聚合：语音取该窗内 37 个低层描述量的均值与标准差；视觉取该窗中点帧的 35 维描述量。对帧率 F_i 与可解码帧数 N_i ，词窗换算为帧区间

$$f_{it}^s = \min\{\lfloor s_{it}F_i \rfloor, N_i - 1\}, \quad f_{it}^e = \min\{\max\{f_{it}^s, \lceil e_{it}F_i \rceil - 1\}, N_i - 1\}. \quad (5.2)$$

掩码语义。三个模态各有一个 $(L,)$ 布尔掩码，true 表示该位置有真实观测，false 表示补零或不可用；三者的交集为 `multimodal_mask`。文本掩码按“该词是否落在 BERT 覆盖范围内”置位。

图 5.3 给出整个网格的结构：由于官方词数随片段变化，50 个槽位在前若干列被填满、其后补零，形成阶梯状边界；扣留样本只在前若干列有文本而无音视频。

5.5 扣留规则

被扣留的 22 条样本只保留文本槽位，其词级语音与视觉位置一律补零，两个掩码同时置 false，**不以样本均值或其他替代值伪装逐词特征**。这样做会让可用样本数下降，但保住了“逐词特征确有逐词证据”这一可核验性；若用样本级均值填充，后续模型会把常数当作观测，问题三的证据定位也会指向不存在的时间位置。

由表 5.3 可见，扣留样本占 22%，是本题数据质量的真实约束，而非本文方法的缺陷：这 22 条的官方转写与音频本就不对应。

5.6 容器声明时长与实际播放时长

容器头声明的时长不等于播放器真正呈现的时长。附件 1 中 90 条 MP4 带有 `edit list`：容器声明的帧数高于解码器实际能产出的帧数，单条最多声明 249 帧冗余，100 条累计虚高 9906 帧。若直接用容器时长 T_i^c 推算最后一帧

$$f_i^{\text{last}} = \lfloor T_i^c F_i \rfloor - 1, \quad (5.3)$$

将有 74 条样本指向不存在的帧，累计越界 165 帧，问题三回读证据时会取到错帧或被静默替换为末帧。故本文以可解码帧数 N_i 与帧率 F_i 定义实际播放时长

$$T_i = \frac{N_i}{F_i}, \quad (5.4)$$

并用 T_i 作为帧区间上界；容器时长与声明帧数作为核查字段一并保存。实测实际播放时长落在 $[2.236, 29.167]$ s，容器声明值为 $[2.257, 29.288]$ s，两者最大相差 0.130 s。需说明的是，题面称附件 1 视频时长介于 2.648 s 与 34.567 s 之间，与附件实际文件不符；本文以实测值为准并如实报告该差异。修正后 100 条样本的词元帧区间全部落在 $[0, N_i - 1]$ 内，越界帧数由 165 降为 0。




图 5.3 50 词槽网格的结构与证据覆盖。(a) 100 条样本 $\times$ 50 个词槽的有效性：蓝色为文本与词级音视频齐备，橙色为仅有文本（扣留样本），灰色为补零；(b) MFA 词窗长度分布；(c) 首个词起始时刻与词间最大静音段，显示转写并不从 0 时刻开始、词间存在真实停顿。

5.7 质量标记

题目要求保留异常样本，不得增删或修改。除上述扣留规则外，本文记录以下质量事实，异常一律保留、不删除也不替换。判定与统计见表 5.3，逐样本明细见 `results/problem1/word_grid_summary.csv`。

表 5.3 附件 1 词级网格的质量事实

类别	样本数	处理方式
获得词级 MFA 时间	78	逐词音视频特征有效
降级为样本级（已知文音不符）	20	文本保留，音视频补零且 <code>mask=false</code>
降级为样本级（MFA 后扣留）	2	同上
识别筛查通过	77	仅作参考，不影响输入
识别筛查疑似不匹配	16	仅作参考，不改变官方文本
识别筛查待复核	5	仅作参考
全程无语音	2	无任何声学证据
词数超出 50 被截断	1	保留前 50 词，截去 15 词
BERT 词元超出 50 被截断	6	词级特征不受影响（编码长度 128）
容器声明帧数高于可解码帧数	90	保留，双口径记录

MFA 自身的对齐质量由独立 QC 给出：TextGrid 与官方词序列的词汇一致性在 69/80 条上完全成立，其余 11 条经词形归并后对齐；68/80 条带有至少一项需复核标志，故逐词时间一律以“暂定”层级记录，不称为人工核验的真值。

5.8 语音与视觉描述量

声学工具链参考 COVAREP 对可复用低层描述量的组织思想^[8]，具体计算由 librosa 完成^[9]。每一帧提取 20 维 MFCC、12 维色度以及 RMS、过零率、谱质心、谱带宽、85% 谱滚降点，共 37 维；在 MFA 词窗内取均值和标准差，形成

$$\mathbf{x}_{it}^A = [\text{mean}(\mathbf{l}), \text{std}(\mathbf{l})] \in \mathbb{R}^{74}. \quad (5.5)$$

视觉行为研究常借助 OpenFace 一类工具提取面部线索^[10]。为控制依赖和提交体积，本文采用轻量、完全可复现的 35 维描述：RGB 与 HSV 均值/标准差 12 维，灰度直方图 8 维，边缘和拉普拉斯纹理 2 维，Farneback 光流统计 5 维，最大人脸框几何 5 维，人脸区域亮度、对比度和边缘密度 3 维。每个词窗读取中点帧；无可检出人脸时只把人脸子向量置零，不把整帧判为缺失——35 维中有 28 维不依赖人脸，仍是有效观测。逐槽人脸存在情况另存于 `vision_face_present`。最终有

$$\mathbf{X}^T \in \mathbb{R}^{100 \times 50 \times 768}, \quad \mathbf{X}^A \in \mathbb{R}^{100 \times 50 \times 74}, \quad \mathbf{X}^V \in \mathbb{R}^{100 \times 50 \times 35}. \quad (5.6)$$

`text_bert` 是另存的 (100, 3, 50) 标准 BERT 输入，与上面 50 个词槽不按标一一对应：它是词元级序列，含 [CLS]、[SEP] 与 [PAD]。做词级融合请使用 `text`、`audio`、`vision` 三个数组与各自掩码。

图 5.4 给出典型样本的词窗对齐；横轴均为原视频秒数，底部三帧由保存的帧号直接回读，而不是把特征序号误作秒数。

5.9 提取结果与完整清单

100 条视频全部成功处理，无失败样本，单次完整运行耗时 196 s。得到 1932 个官方词，其中 1593 个词获得有效 MFA 时间，覆盖 78 条样本。50 词槽网格中，文本槽位有观测 1917 个、语音 1578 个、视觉 1578 个（其中 1451 个检出人脸）。1 条样本词数超 50 被截断，共截去 15 词；6 条样本的 BERT 词元超 50，但词级文本特征不受影响。实际播放时长为 2.236–29.167 s，平均 7.82 s。

为验证实现，本文把词槽文本、逐词时间、长度与截断口径、文本与语音掩码与上游独立装配结果逐位比对：样本顺序、词槽文本（0 处不符）、时间（NaN 模式一致，最大差




图 5.4 典型样本的词级对齐示例

4.7×10^{-7} s)、长度口径与两个掩码均完全一致；词级文本特征的逐槽相关系数中位数为 0.976。视觉掩码口径不同（见 5.4 节），差异 24 处，已如实记录。

表 5.4 附件 1 提取概况

统计量	负向	中性	正向	合计
样本数	18	25	57	100
比例/%	18.0	25.0	57.0	100.0

表 5.5 附件 1 词级网络清单（对齐粒度：官方词；特征维度：文本 50×768 、语音 50×74 、视觉 50×35 ）

序号	样本标识	时长/s	词数	词级时间	文本/音视频槽	强度（极性）
1	-3g5yACwYnA/13	5.43	15	15	15/15	0.667
正向						
2	-3g5yACwYnA/3	14.37	29	29	29/29	0.000
中性						
3	-3g5yACwYnA/2	9.27	14	14	14/14	0.000
中性						
4	-3g5yACwYnA/9	8.77	23	23	23/23	0.667
正向						
5	-3nNcZdcdvU/5	7.87	18	18	18/18	0.000
中性						

下页续表

续表 5.5

序号	样本标识	时长/s	词数	词级时间	文本/音视频槽	强度（极性）
6	-HwX2H8Z4hY/2	3.97	7	扣留	7/0	0.000
中性						
7	-HwX2H8Z4hY/5	5.60	9	9	9/9	-1.000
负向						
8	-HwX2H8Z4hY/6	3.30	7	7	7/7	0.000
中性						
9	-HwX2H8Z4hY/9	7.73	22	22	22/22	-0.333
负向						
10	-NFrJFQijFE/1	5.68	16	扣留	16/0	0.333
正向						
11	-NFrJFQijFE/2	6.76	18	扣留	18/0	0.000
中性						
12	-THoVjtIkeU/12	14.83	39	39	39/39	2.000
正向						
13	-THoVjtIkeU/2	4.27	10	10	10/10	1.333
正向						
14	-THoVjtIkeU/6	8.03	30	30	30/30	2.667
正向						
15	-UuXlxuaiiE/1	10.30	27	27	27/27	1.667
正向						
16	-UuXlxuaiiE/0	3.63	9	9	9/9	2.667
正向						
17	-UuXlxuaiiE/3	4.10	9	9	9/9	0.333
正向						
18	-UuXlxuaiiE/6	8.00	22	22	22/22	-0.333
负向						
19	-a55Q6RWvTA/3	22.13	65→50	50	50/50	0.667
正向						
20	-aNfi7CP8vM/7	8.57	18	18	18/18	0.000
中性						
21	-aqamKhZlEc/0	10.97	14	14	14/14	-2.000
负向						
22	-dxftGcXJoc/1	16.07	37	扣留	37/0	1.667
正向						
23	-dxftGcXJoc/0	20.50	40	40	40/40	1.000
正向						
24	-dxftGcXJoc/2	16.67	34	34	34/34	0.667
正向						
25	-dxftGcXJoc/6	12.70	28	28	28/28	0.667
正向						
26	-egA8-b7-3M/26	5.97	15	15	15/15	1.667
正向						
27	-egA8-b7-3M/17	7.17	16	16	16/16	0.333
正向						
28	-egA8-b7-3M/18	8.33	22	22	22/22	1.000
正向						
29	-egA8-b7-3M/16	5.53	11	11	11/11	0.667
正向						
30	-egA8-b7-3M/13	4.10	11	11	11/11	0.333
正向						
31	-egA8-b7-3M/1	10.20	20	20	20/20	0.667
正向						
32	-egA8-b7-3M/6	6.23	12	12	12/12	0.667
正向						
33	-egA8-b7-3M/9	5.00	10	10	10/10	0.333
正向						
34	-egA8-b7-3M/20	6.53	20	20	20/20	0.333
正向						
35	-iRBcNs9oI8/3	5.57	8	扣留	8/0	0.667
正向						
36	-iRBcNs9oI8/7	4.00	9	扣留	9/0	0.667
正向						
37	-iRBcNs9oI8/6	2.84	5	扣留	5/0	0.333
正向						
38	-iRBcNs9oI8/9	3.40	5	扣留	5/0	1.333
正向						
39	-iRBcNs9oI8/8	8.04	21	扣留	21/0	1.000
正向						
40	-lzEya4AM_4/5	7.63	19	19	19/19	-0.667
负向						
41	-lzEya4AM_4/6	14.77	43	43	43/43	-0.333
负向						
42	-mJ2ud6oKI8/1	6.07	13	扣留	13/0	0.000
中性						
43	-mJ2ud6oKI8/2	5.71	11	扣留	11/0	0.000
中性						
44	-mJ2ud6oKI8/6	2.24	5	扣留	5/0	0.333
正向						
45	-mJ2ud6oKI8/9	6.94	22	扣留	22/0	0.000
中性						
46	-mJ2ud6oKI8/8	4.17	11	扣留	11/0	-0.333
负向						
47	-mqbVkbCndg/0	6.47	14	14	14/14	0.000

下页续表

续表 5.5

序号	样本标识	时长/s	词数	词级时间	文本/音视频槽	强度 (极性)
中性						
48	-t217m2on-s/2	5.67	12	12	12/12	0.667
正向						
49	-t217m2on-s/7	17.07	45	45	45/45	-0.667
负向						
50	-tANM6ETl_M/3	6.67	22	22	22/22	0.333
正向						
51	-tPCytz4rww/11	5.47	17	17	17/17	0.000
中性						
52	-tPCytz4rww/10	4.73	12	12	12/12	0.000
中性						
53	-tPCytz4rww/12	11.77	26	26	26/26	0.000
中性						
54	-tPCytz4rww/16	7.20	16	16	16/16	0.000
中性						
55	-tPCytz4rww/18	6.63	16	16	16/16	0.000
中性						
56	-vxjVxOeScU/4	9.07	21	21	21/21	1.000
正向						
57	-wMB_hJL-3o/7	6.03	22	22	22/22	0.333
正向						
58	-wny00Az3g8/1	6.83	22	22	22/22	0.333
正向						
59	-wny00Az3g8/0	3.33	9	9	9/9	0.333
正向						
60	-wny00Az3g8/3	6.13	20	20	20/20	-1.333
负向						
61	-wny00Az3g8/2	6.57	23	23	23/23	-0.333
负向						
62	-wny00Az3g8/5	6.80	20	20	20/20	1.000
正向						
63	-wny00Az3g8/7	8.00	29	29	29/29	0.000
中性						
64	-wny00Az3g8/9	6.10	20	20	20/20	0.667
正向						
65	-571d8cVauQ/0	5.07	12	12	12/12	0.000
中性						
66	-571d8cVauQ/5	15.17	43	43	43/43	0.333
正向						
67	-I_e4mIh0yE/1	7.50	18	18	18/18	-0.667
负向						
68	-I_e4mIh0yE/3	9.03	22	22	22/22	0.667
正向						
69	-UacrmKiTn4/10	7.27	18	18	18/18	-0.667
负向						
70	-UacrmKiTn4/4	4.73	14	14	14/14	-1.333
负向						
71	-hnBHBn8p5A/7	7.34	13	扣留	13/0	0.667
正向						
72	-hnBHBn8p5A/6	6.38	13	扣留	13/0	1.000
正向						
73	-qDkUB0GgYY/6	4.67	16	16	16/16	1.333
正向						
74	-uywlfIYOS8/4	5.97	18	18	18/18	0.333
正向						
75	-6rXp3zJ3kc/8	12.80	34	34	34/34	-1.000
负向						
76	-9y-fZ3swSY/0	6.83	22	22	22/22	1.000
正向						
77	-9y-fZ3swSY/4	2.70	9	9	9/9	0.000
中性						
78	-9y-fZ3swSY/8	4.97	12	12	12/12	1.667
正向						
79	-AUZQgSxyPQ/2	22.47	41	41	41/41	0.667
正向						
80	-HeZS2-Prhc/2	8.20	16	16	16/16	0.667
正向						
81	-MeTTeMJBNC/0	9.30	21	21	21/21	0.333
正向						
82	-MeTTeMJBNC/13	5.30	14	14	14/14	0.333
正向						
83	-MeTTeMJBNC/7	10.47	31	31	31/31	1.333
正向						
84	-RfYyzHpjk4/11	5.13	17	17	17/17	2.000
正向						
85	-RfYyzHpjk4/8	4.57	17	17	17/17	0.333
正向						
86	-RfYyzHpjk4/2	5.47	25	25	25/25	0.333
正向						
87	-UUCSKoHeMA/0	7.80	18	18	18/18	0.000
中性						
88	-ri04Z7vwnc/0	2.79	8	扣留	8/0	0.000
中性						

下页续表

续表 5.5

序号	样本标识	时长/s	词数	词级时间	文本/音视频槽	强度（极性）
89	-ri04Z7vwnc/2	5.96	16	扣留	16/0	-0.333
负向						
90	-ri04Z7vwnc/5	3.46	8	扣留	8/0	0.333
正向						
91	-s9qJ7ATP7w/1	4.67	11	11	11/11	0.667
正向						
92	-s9qJ7ATP7w/0	6.80	24	24	24/24	-0.333
负向						
93	-s9qJ7ATP7w/5	8.43	19	19	19/19	-2.000
负向						
94	-s9qJ7ATP7w/4	4.30	9	9	9/9	0.000
中性						
95	-s9qJ7ATP7w/7	6.90	28	28	28/28	1.000
正向						
96	-s9qJ7ATP7w/6	2.37	5	5	5/5	0.000
中性						
97	-s9qJ7ATP7w/8	3.23	12	12	12/12	1.333
正向						
98	-yRb-Jum7EQ/1	29.17	49	扣留	49/0	0.000
中性						
99	-yRb-Jum7EQ/5	13.13	25	扣留	25/0	-0.667
负向						
100	-yRb-Jum7EQ/6	11.20	19	扣留	19/0	0.000
中性						

5.10 问题一核对清单

本问已经核对：输入为 100 个 MP4、100 行标签及其转写；每个样本均输出 50×768 、 50×74 、 50×35 三类特征与三个掩码；标签符号遵循负、零、正三段规则；时间映射保存秒数与帧区间，且全部帧号落在可解码范围内。文本始终取自 label-100.xlsx，声学模型只提供时间、不提供任何进入特征的文字，未引入外部情感标注数据。22 条文音不符样本按扣留规则处理，未用样本均值伪装逐词特征。逐词时间来自自动强制对齐并标为“暂定”，不冒称为人工核验的逐词真值。内部零行只作观测状态记录，不推断其成因。

6 问题二：缺失感知多模态预测

6.1 统一文本支路与三类掩码

附件 2 的 text_bert 形状为 3×50 ，三行依次为 token id、attention mask 和 token type id；后两行分别只含 $\{0, 1\}$ 和 $\{0\}$ 。训练、验证、测试均把它送入同一个冻结 BERT 编码器，得到 50×768 隐层表征。附件 3 的对应数组先检查有限性和整数值，再从 float32 转为 int64。附件 2 中另存的 text 只用于审计，不进入任何模型。该做法消除了“训练用旧文本向量、预测改用 BERT”的表征漂移。

对于样本 i ，令文本掩码非零、语音行非零、视觉行非零的并集最后位置为 ℓ_i ，排除第 0 个结构位置和末端结构位置后，定义有效内容时间线

$$u_{it} = \mathbb{I}(0 < t < \ell_i). \quad (6.7)$$

随后分别定义

$$\begin{aligned} o_{it}^T &= u_{it} \mathbb{I}(\text{attention}_{it} = 1), \\ o_{it}^A &= u_{it} \mathbb{I}(\|\mathbf{x}_{it}^A\|_0 > 0), \\ o_{it}^V &= u_{it} \mathbb{I}(\|\mathbf{x}_{it}^V\|_0 > 0). \end{aligned} \quad (6.8)$$

式 (6.8) 把三类状态分开： $u = 1, o = 1$ 为观测内容， $u = 1, o = 0$ 为区内未观测或可疑位置， $u = 0$ 为结构边界或尾部填充。语音和视觉只用训练集观测位置估计均值与标准差，再将同一标准化器应用于验证、测试和附件 3、4。

6.2 缺失标记时序编码器

不同模态先线性投影到 $d = 96$ 维。对于未观测位置，不将全零直接送入网络，而用模态专属的可学习缺失标记 $\mathbf{q}^m$ 替换：

$$\mathbf{z}_{it}^m = o_{it}^m P_m(\mathbf{x}_{it}^m) + (1 - o_{it}^m) \mathbf{q}^m + \mathbf{p}_t, \quad (6.9)$$

其中 $\mathbf{p}_t$ 为可学习位置编码。每个模态使用一层、4 头时序 Transformer，前馈维数为 $3d$ ，仅用 u_{it} 屏蔽真正的尾部位置。时序注意力汇聚为

$$\alpha_{it}^m = \text{softmax}_{t:u_{it}=1} [\mathbf{w}_{m2}^\top \tanh(\mathbf{W}_{m1} \mathbf{H}_{it}^m)], \quad \mathbf{h}_i^m = \sum_t \alpha_{it}^m \mathbf{H}_{it}^m. \quad (6.10)$$

为使局部缺失直接影响融合，定义观测可靠度

$$\rho_i^m = \frac{\sum_t o_{it}^m}{\sum_t u_{it}}, \quad (6.11)$$

并在门控对数几率中加入 $\log(\rho_i^m + 0.05)$ ：

$$a_i^m = G_m([\mathbf{h}_i^m; \rho_i^m]) + \log(\rho_i^m + 0.05), \quad g_i^m = \frac{\exp a_i^m}{\sum_n \exp a_i^n}. \quad (6.12)$$

最终表示为 $\mathbf{h}_i = \sum_m g_i^m \mathbf{h}_i^m$ 。分类头输出三类 softmax；回归头输出

$$\hat{y}_i^{\text{raw}} = 3 \tanh(\mathbf{w}_r^\top \mathbf{h}_i + b_r), \quad (6.13)$$

自然限制在 $[-3, 3]$ 。这一结构吸收了多模态交互方法^[2,3]与缺失模态统一建模^[11]的优点，但针对本题将“局部观测率”明确写入门控。

6.3 局部缺失增强与多任务损失

训练时对每个样本、每个模态以 0.45 概率选择一个连续区块，区块长度在有效长度的 10%–40% 之间均匀采样，只把相应 o_{it}^m 置零，不改变 u_{it} ，也不整段删除样本。这样模型在已知时间位置上看到缺失标记，而不是把缺失与尾部填充混淆。

总损失为

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + 0.60 \mathcal{L}_{\text{Huber}} + 0.20(1 - r_B) + 0.10 \left\| \sum_{k=0}^2 p_{ik} [-1, 0, 1]_k - \frac{\hat{y}_i^{\text{raw}}}{3} \right\|_2^2, \quad (6.14)$$

其中 r_B 是批内预测强度与真实强度的 Pearson 相关系数。交叉熵使用平方根反频率类别权重；Huber 阈值为 0.5。最后一项约束分类概率的期望极性与回归符号一致。

训练使用 AdamW，学习率 3×10^{-4} 、权重衰减 10^{-4} 、批量 64、dropout 0.20、随机种子 2026。只依据验证集综合分

$$S = 0.50 \text{MacroF1} + 0.30 \frac{r + 1}{2} + 0.20 \max \left(0, 1 - \frac{\text{MAE}}{3} \right) \quad (6.15)$$

保存检查点并早停，最优检查点位于第 6 轮；测试集不参与式 (6.15)。

为严格执行“负、零、正”的标签定义，分类后对强度作最小幅度符号投影， $\varepsilon = 10^{-3}$ ：

$$\hat{y}_i = \begin{cases} \min(\hat{y}_i^{\text{raw}}, -\varepsilon), & \hat{c}_i = 0, \\ 0, & \hat{c}_i = 1, \\ \max(\hat{y}_i^{\text{raw}}, \varepsilon), & \hat{c}_i = 2. \end{cases} \quad (6.16)$$

该规则不是从附件 3、4 调出的阈值，而是题面标签语义的确定性约束。

6.4 评价指标与固定模型结果

分类使用 Accuracy 与三类 F1 的算术平均 Macro-F1；回归使用

$$\text{MAE} = \frac{1}{N} \sum_i |y_i - \hat{y}_i|, \quad r = \frac{\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_i (y_i - \bar{y})^2 \sum_i (\hat{y}_i - \bar{\hat{y}})^2}}. \quad (6.17)$$

表 6.6 给出点估计和 2,000 次样本重采样的 95% 区间。该区间只刻画固定预测上的样本不确定性，不是多随机种子训练区间。

表 6.6 固定模型性能

数据	Accuracy	Macro-F1	MAE	Pearson r
验证集	0.628	0.608	0.625	0.644
95% 区间	[0.592,0.663]	[0.570,0.645]	[0.583,0.669]	[0.594,0.694]
测试集	0.624	0.584	0.668	0.658
95% 区间	[0.589,0.657]	[0.546,0.617]	[0.621,0.715]	[0.603,0.710]




图 6.5 固定模型性能

图 6.5 显示，测试集负向和正向召回率分别为 0.79 和 0.65，而中性召回率为 0.36。原因之一是中性在训练集中只有 758 条，少于正向的 1,670 条；同时中性必须落在严格零点，比正负两个开区间更难。验证与测试的 Pearson 系数接近且测试略高，说明模型选择没有依赖测试回归结果。

图 6.6 给出训练轨迹、门控权重和消融。完整动态门控的验证综合分为 0.7088；仅文本为 0.7080，去除视觉和去除语音分别为 0.7034、0.7016，而等权融合降至 0.6845。可见文本是主导信息，但视听模态和可靠度门控仍提供小而稳定的互补；不应把“多模态”夸大为远超文本基线。




图 6.6 训练与消融结果

6.5 附件 3 固定模型预测

附件 3 按文件名排序读取 30 个对齐文件，预测结果集合与文件名集合完全相等且无重复。固定模型输出负向 12 条、中性 5 条、正向 13 条；图 6.7 展示强度和观测率，完整数值见表 6.7。音频和视觉中观察到的同步零块被记入观测率，但本文不把其成因写成已证实事实。




图 6.7 附件 3 固定模型预测

表 6.7 附件 3 预测结果

文件名	极性	强度	置信度	g_T	g_A	g_V	音/视觉测率
附件 3_01	负向	-1.054	0.851	0.688	0.179	0.134	1.000/1.000
附件 3_02	中性	0.000	0.600	0.570	0.099	0.331	0.821/0.821
附件 3_03	负向	-0.929	0.690	0.644	0.142	0.214	0.844/0.719
附件 3_04	正向	0.287	0.540	0.455	0.281	0.264	0.935/0.935
附件 3_05	负向	-1.754	0.926	0.736	0.106	0.159	1.000/1.000
附件 3_06	正向	1.200	0.926	0.456	0.211	0.334	0.880/0.880
附件 3_07	中性	0.000	0.435	0.546	0.150	0.304	0.857/0.857
附件 3_08	正向	0.001	0.377	0.738	0.118	0.144	0.867/0.867
附件 3_09	正向	1.411	0.943	0.515	0.137	0.348	0.857/0.857
附件 3_10	中性	0.000	0.804	0.509	0.183	0.307	1.000/1.000
附件 3_11	负向	-0.001	0.433	0.634	0.218	0.148	0.714/0.714
附件 3_12	正向	0.575	0.752	0.594	0.162	0.244	0.846/0.846
附件 3_13	负向	-0.664	0.667	0.619	0.240	0.141	0.895/0.895
附件 3_14	负向	-0.418	0.618	0.564	0.200	0.236	0.913/0.913
附件 3_15	正向	0.951	0.877	0.524	0.167	0.309	0.889/0.889
附件 3_16	正向	0.996	0.872	0.516	0.125	0.358	0.882/0.882
附件 3_17	负向	-1.156	0.862	0.744	0.129	0.127	0.636/0.636
附件 3_18	正向	0.242	0.473	0.435	0.216	0.349	0.824/0.824
附件 3_19	负向	-0.961	0.777	0.653	0.154	0.193	0.708/0.708
附件 3_20	负向	-0.930	0.702	0.648	0.127	0.225	0.708/0.708
附件 3_21	正向	0.677	0.744	0.673	0.117	0.210	0.667/0.667
附件 3_22	正向	0.152	0.437	0.539	0.255	0.206	0.765/0.765
附件 3_23	中性	0.000	0.609	0.668	0.096	0.235	0.692/0.692
附件 3_24	负向	-1.364	0.925	0.752	0.133	0.116	0.750/0.750

下页续表

续表 6.7

文件名	极性	强度	置信度	g_T	g_A	g_V	音/视觉测率
附件 3_25	负向	-0.861	0.527	0.770	0.115	0.115	0.778/0.778
附件 3_26	正向	0.800	0.662	0.639	0.144	0.217	0.727/0.727
附件 3_27	正向	0.634	0.723	0.504	0.221	0.275	0.619/0.619
附件 3_28	中性	0.000	0.488	0.618	0.171	0.211	0.667/0.667
附件 3_29	正向	0.341	0.575	0.633	0.189	0.178	0.556/0.556
附件 3_30	负向	-0.580	0.655	0.654	0.173	0.173	0.500/0.500

6.6 问题二核对清单

本问已经核对：附件 2 的训练、验证、测试样本数分别为 3,395、728、727；输入字段为 text_bert、audio、vision 和标签；三类标签按 $< 0, = 0, > 0$ 编码为 0、1、2；附件 3 的 30 个文件以文件名映射且文本整数化后进入同一 BERT；局部缺失、结构位置和尾部填充分别处理。附件 3 无真值，故表 6.7 不附“准确率”。

7 问题三：多模态作用与证据回溯

7.1 门控一反事实联合解释

问题三直接加载问题二第 6 轮固定检查点和训练集标准化器，不重新训练，也不根据附件 4 的输出调整阈值。对样本 i ，首先得到原预测概率 $\mathbf{p}_i$ 和原始强度 $\hat{g}_i^{\text{raw}}$ 。若移除某个模态或位置后输出为 $(\mathbf{p}'_i, \hat{g}'_i)$ ，定义归一化输出距离

$$d_i = \frac{1}{2} \|\mathbf{p}'_i - \mathbf{p}_i\|_1 + \frac{|\hat{g}'_i - \hat{g}_i^{\text{raw}}|}{6}. \quad (7.18)$$

第一项是三分类分布的总变差距离，第二项按强度全量程 6 归一化。整模态移除得到 D_i^m ，再归一化为 $\tilde{D}_i^m$ 。最终模态作用程度为

$$R_i^m = \frac{0.5g_i^m + 0.5\tilde{D}_i^m}{\sum_n (0.5g_i^n + 0.5\tilde{D}_i^n)}. \quad (7.19)$$

式 (7.19) 同时考虑模型在正常前向传播时的门控和真正遮蔽后的输出变化，避免只依赖一种解释信号。

对模态 m 的每个观测位置 t 单独遮蔽，得到距离 d_{it}^m ，并与原时序注意力结合：

$$I_{it}^m = \frac{d_{it}^m \sqrt{\alpha_{it}^m}}{\sum_{s: o_{is}^m=1} d_{is}^m \sqrt{\alpha_{is}^m}}. \quad (7.20)$$

若分母近似为零，则退化为归一化注意力。文本位置向两侧扩展两个词元形成可读短语；语音直接报告 $[s_{it}, e_{it}]$ ；视觉报告窗口中点秒数和原帧号。故解释中的“第 t 个特征”不会被直接说成“第 t 秒”。

7.2 附件 4 总体结果

20 条样本的固定模型输出为负向 8 条、中性 4 条、正向 8 条。平均模态作用程度为文本 0.654、语音 0.166、视觉 0.181，20 条样本的最大作用模态均为文本。图 7.8 同时给出逐样本构成、极性强度和跨样本差异；这说明当前数据上的文本主导性很强，也提示音视频支路的边际贡献有限。




图 7.8 附件 4 解释总览

完整预测与模态作用见表 7.8。另外保存 1,662 行逐位置重要性、每模态前三位证据和 57 张关键帧；当某条样本不足 3 个可观测视觉位置时不复制帧凑数。

表 7.8 附件 4 解释汇总

样本	极性	强度	置信度	主模态	R_T	R_A	R_V
01	中性	0.000	0.687	文本	0.704	0.109	0.188
02	正向	0.001	0.411	文本	0.580	0.270	0.150
03	负向	-0.414	0.599	文本	0.517	0.262	0.221
04	负向	-0.322	0.695	文本	0.594	0.228	0.178
05	正向	0.394	0.623	文本	0.403	0.221	0.376
06	正向	0.485	0.746	文本	0.742	0.136	0.123
07	正向	0.822	0.836	文本	0.673	0.095	0.232
08	中性	0.000	0.614	文本	0.359	0.286	0.354
09	负向	-2.078	0.960	文本	0.815	0.066	0.119
10	负向	-1.982	0.956	文本	0.843	0.064	0.093
11	负向	-1.823	0.933	文本	0.758	0.106	0.136
12	负向	-1.132	0.891	文本	0.830	0.094	0.076
13	中性	0.000	0.619	文本	0.696	0.293	0.011
14	中性	0.000	0.724	文本	0.722	0.111	0.166
15	正向	0.527	0.809	文本	0.551	0.261	0.188
16	负向	-2.269	0.970	文本	0.892	0.053	0.055
17	正向	1.042	0.875	文本	0.622	0.213	0.165
18	负向	-0.518	0.618	文本	0.659	0.158	0.183
19	正向	0.048	0.483	文本	0.624	0.077	0.298
20	正向	0.706	0.825	文本	0.488	0.212	0.300

7.3 典型样本的原材料证据链

选择置信度最高且三类证据齐全的样本 16 进行展开。模型预测为负向，强度 -2.269 ，置信度 0.970 ；文本、语音、视觉作用程度分别为 0.892 、 0.053 、 0.055 。图 7.9 的热图给出逐位置重要性，下部照片直接由附件 4 原视频按映射帧号回读。




图 7.9 样本 16 证据回溯

其原始转写为 “It’s a terrible, this is a terrible movie”。文本前三窗口为 “it’s”、“this is a terrible movie” 和 “’s a terrible,”；其中第二、第三窗口包含明确的负向词 terrible。语音前三时段为 2.23–2.74 s、2.89–3.11 s 和 2.81–2.89 s。视觉前三证据映射到约 1.96 s/第 59 帧、0.46 s/第 14 帧和 2.11 s/第 63 帧。文字、语音和画面均可回到同一原视频复核。

需要强调，式 (7.20) 衡量的是对当前模型输出的反事实敏感度，并不是人类情感形成过程的因果效应。例如收缩词 “it’s” 的高分可能来自上下文边界关联，不能脱离完整短语解释为负面词。

7.4 问题三核对清单

本问已经核对：附件 4 共 20 个样本且没有真实标签；输入继续使用对齐版 text_bert、语音和视觉，模型、BERT 权重、词表、标准化器和符号投影均与问题二一致；全部关键语音段和视觉帧均含原视频时间映射。因无真值，本文只报告预测分布、置信度和模型作用程度，不以任何假定标签调参，也不声称附件 4 的真实准确率。

8 鲁棒性与敏感性分析

8.1 连续缺失率敏感性

在固定验证集上构造 10%、20%、30%、40%、50% 的连续缺失区块，分别放在有效内容的前段、中段和后段；缺失类型包括文本、语音、视觉以及语音与视觉同时缺失。每个设置只改变观测掩码，不移动标签或尾部边界。表 8.9 按缺失率汇总 12 种“类型 × 位置”组合。

表 8.9 连续缺失率敏感性

缺失率	Macro-F1		MAE		综合分	
	增强	无增强	增强	无增强	增强	无增强
10%	0.6043	0.6127	0.6254	0.6380	0.7069	0.7069
20%	0.6032	0.6046	0.6251	0.6401	0.7063	0.7024
30%	0.6010	0.5987	0.6247	0.6418	0.7051	0.6990
40%	0.5966	0.5932	0.6258	0.6432	0.7022	0.6955
50%	0.5923	0.5856	0.6275	0.6472	0.6990	0.6904

在轻微缺失 10% 时，两模型综合分相同，且无增强模型的 Macro-F1 略高；缺失率达到 30% 以后，增强模型在综合分、MAE 上持续更优。在全部压力场景上，增强与无增强模型的平均 Macro-F1 分别为 0.5995、0.5990，平均 MAE 为 0.6257、0.6420，平均 Pearson r 为 0.6392、0.6145，平均综合分为 0.7039、0.6988。由此可把局部缺失增强的收益准确表述为“主要提高中高缺失率下的回归稳定性”，而不是无条件提升所有指标。




图 8.10 连续缺失鲁棒性

8.2 模态与位置敏感性

按缺失模态平均，增强模型在文本缺失下的综合分为 0.6967，无增强模型为 0.6776，增益最大；视觉缺失、语音缺失及音视同步缺失的两模型差距较小。这与消融实验的文本主导结论一致：训练时遮蔽文本能迫使模型利用音视频补偿。

增强模型在前、中、后段缺失下的平均综合分分别为 0.7047、0.7023、0.7047，中段略低但差值不超过 0.0025。这说明模型对缺失位置不高度敏感。该结果只针对人工压力场景，不代表已识别出附件中零块的真实产生机制。

8.3 模型选择与后处理敏感性

干净验证集上，增强模型综合分 0.7088，无增强模型 0.7079，点估计仅相差 0.0009。对两个固定预测做 2,000 次成对样本重采样，差值 95% 区间为 $[-0.0128, 0.0145]$ ，跨越 0。因此选择增强模型的主要理由是压力测试下的总体稳定性，而非宣称干净集差异显著。

符号投影前后也做了复核。验证集 MAE 从 0.6454 降至 0.6252，Pearson r 从 0.6416 变为 0.6442；测试集 MAE 从 0.6732 降至 0.6679，而 r 从 0.6638 降至 0.6580。投影改善了与三分类规则一致的绝对误差，但不保证相关系数同时上升，故正文同时保留 `raw_predicted_intensity` 供复算。

9 模型评价、结论与推广

9.1 模型优点

- (1) **输入定义统一。**三个数据阶段都由同一 text_bert、同一 BERT 和同一标准化器处理，避免了文本表征在训练与预测时切换。
- (2) **缺失建模符合题意。**模型显式区分内容、区内未观测和尾部填充，并在连续局部区间而非仅在整模态层面做增强。
- (3) **分类与回归相互约束。**多任务一致性损失和严格符号投影共同保证负、零、正标签语义；原始强度同时保留，后处理可审计。
- (4) **结果可回溯。**从附件 1 开始保存秒数与帧号，问题三的关键文字、语音段和画面均能回到原文件核对。
- (5) **结论边界清楚。**选模只使用训练、验证划分；固定测试集单独评估；附件 3、4 无标签，未被用于调参或虚构准确率。

9.2 模型局限

- (1) 累计语音能量对齐只保证单调和全覆盖，快速连读、长停顿或背景声较强时可能偏离真实词边界；若规则允许，可用人工校准或强制对齐器替代。
- (2) 模型明显依赖文本。完整模型相对仅文本基线的干净验证综合分只提高 0.0008，音视频价值主要体现在缺失压力下，不能据此宣称强跨模态增益。
- (3) 观测掩码仍部分依赖零行诊断。本文没有把零值原因当作事实，但未知的有效零向量与采集缺失仍可能混淆。
- (4) 受计算资源限制，训练采用一个预注册随机种子；bootstrap 区间只反映样本重采样，不包括不同初始化带来的方差。
- (5) 附件 3、4 没有真值，置信度与解释只能说明固定模型自身的判断结构。部署前仍需在目标域有标签样本上校准。

9.3 结论

本文完成了三问闭环。问题一对 100 条视频全部成功提取三模态对齐特征，并形成逐词元秒数与帧号映射；问题二用附件 2 的 3,395/728/727 划分训练、选模和测试，在固定测试集上取得 Accuracy 0.624、Macro-F1 0.584、MAE 0.668、Pearson $r = 0.658$ ，并生成附件 3 全部 30 条预测；问题三对附件 4 全部 20 条生成预测、模态作用程度和原材料证据，其中平均作用度为文本 0.654、语音 0.166、视觉 0.181。压力测试说明局部缺失增强的优势集中在中高缺失率与文本缺失场景。

模型可推广到客户评论视频、在线课堂反馈和访谈质检等“文本主导但音视频可补偿”的任务。迁移时应重新估计训练域标准化参数，保留文件一时间一帧映射，并在目标域有标签验证集上重新校准，而不能直接沿用附件 3、4 的无标签输出。

9.4 可复现性与工具说明

所有表格和图形均由提交代码从 CSV/JSON 结果重新生成；BERT 名称、缓存提交号、随机种子、依赖版本和模型参数随附件记录。报告写作与代码检查使用 MathModel Desktop 中的 OpenAI GPT-5 系列模型辅助组织候选文本和检查清单，运行记录日期为 2026-09-24；所有数据读取、训练、指标、图表与引用均由本地脚本或 DOI 元数据复算，未把模型生成的未核验数值作为结果。最终模型选择、事实核对和论文结论由参赛者负责。

参考文献

- [1] AmirAli Bagher Zadeh, Paul Pu Liang, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, pages 2236–2246, 2018. doi: 10.18653/v1/p18-1208.
- [2] Amir Zadeh, Minghai Chen, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Tensor fusion network for multimodal sentiment analysis. In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, pages 1103–1114, 2017. doi: 10.18653/v1/d17-1115.
- [3] Yao-Hung Hubert Tsai, Shaojie Bai, Paul Pu Liang, J. Zico Kolter, Louis-Philippe Morency, and Ruslan Salakhutdinov. Multimodal transformer for unaligned multimodal language sequences. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 6558–6569, 2019. doi: 10.18653/v1/p19-1656.
- [4] Ronghao Lin and Haifeng Hu. MissModal: Increasing robustness to missing modality in multimodal sentiment analysis. Transactions of the Association for Computational Linguistics, 11:1686–1702, 2023. doi: 10.1162/tacl_a_00628.
- [5] Zhizhong Liu, Bin Zhou, Dianhui Chu, Yuhang Sun, and Lingqiang Meng. Modality translation-based multimodal sentiment analysis under uncertain missing modalities. Information Fusion, 101:101973, 2024. doi: 10.1016/j.inffus.2023.101973.
- [6] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. Why should i trust you? explaining the predictions of any classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages 1135–1144, 2016. doi: 10.1145/2939672.2939778.
- [7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics, pages 4171–4186, 2019. doi: 10.18653/v1/n19-1423.
- [8] Gilles Degottex, John Kane, Thomas Drugman, Tuomo Raitio, and Stefan Scherer. COVAREP: A collaborative voice analysis repository for speech technologies. In 2014 IEEE International Conference on Acoustics, Speech and Signal Processing, pages 960–964, 2014. doi: 10.1109/icassp.2014.6853739.
- [9] Brian McFee, Colin Raffel, Dawen Liang, Daniel Ellis, Matt McVicar, Eric Battenberg, and Oriol Nieto. librosa: Audio and music signal analysis in python. In Proceedings of the 14th Python in Science Conference, pages 18–24, 2015. doi: 10.25080/majora-7b98e3ed-003.
- [10] Tadas Baltrusaitis, Amir Zadeh, Yao Chong Lim, and Louis-Philippe Morency. OpenFace 2.0: Facial behavior analysis toolkit. In 2018 13th IEEE International Conference on Automatic Face and Gesture Recognition, pages 59–66, 2018. doi: 10.1109/fg.2018.00019.
- [11] Ruohong Huan, Guowei Zhong, Peng Chen, and Ronghua Liang. UniMF: A unified multimodal framework for multimodal sentiment analysis in missing modalities and unaligned multimodal sequences. IEEE Transactions on Multimedia, 26:5753–5768, 2024. doi: 10.1109/tmm.2023.3338769.

附录 A 复现说明与核心算法

A.1 核心算法伪代码

Input: 附件 2 训练集、验证集，随机种子 2026
Output: 验证综合分最优的固定检查点
读取三模态并由式 (6.8) 生成内容与观测掩码;
用训练集观测位置拟合语音、视觉标准化器;
冻结同一 BERT，缓存训练、验证、测试文本隐层;
for 每个训练批次 **do**
 在有效内容内按模态随机遮蔽一个连续区块;
 以缺失标记编码三条时序，并由式 (6.12) 动态融合;
 按式 (6.14) 反向传播并更新融合模型;
end
每轮只在验证集计算式 (6.15) 并保存最优检查点;
固定检查点后评估测试集并预测附件 3;

算法 1: 局部缺失感知训练

Input: 固定检查点、附件 4、词元时间帧映射
Output: 模态作用度、关键文字、语音段和视频帧
计算原预测、动态门控和时序注意力;
逐模态整体遮蔽，由式 (7.18) 求反事实距离;
由式 (7.19) 计算三模态作用度;
逐观测位置遮蔽，由式 (7.20) 计算局部重要性;
选每模态前三位，将位置映射为词元窗口、秒数和原帧号;

算法 2: 原材料证据回溯

A.2 文件与职责

表 A.1 核心程序清单

文件	职责
code/inspect_inputs.py	审计四个附件的字段、形状、样本数、标签和零行位置
code/media_alignment.py	视频解码、累计能量对齐、74 维语音和 35 维视觉描述量、帧回读
code/problem1_extract.py	对附件 1 的 100 条视频生成逐样本压缩特征和追踪表
code/cache_bert_features.py	以同一冻结 BERT 缓存附件 2-4 文本隐层
code/robust_model.py	时序编码、缺失标记、可靠度门控、多任务损失和连续区块增强
code/problem2_train.py	单模型训练、验证选模、测试评估、压力测试和附件 3 预测
code/problem3_explain.py	整模态及逐位置反事实解释、时间帧映射和关键帧导出
code/analyze_results.py	固定预测的 bootstrap 区间与成对模型比较
code/make_figures.py	统一生成全部 SVG/PDF/PNG 科研图及图源数据
code/generate_latex_tables	由结果 CSV 生成 100、30、20 条完整长表
.PY	

A.3 推荐复现顺序

在项目根目录的 PowerShell 中执行：

```
.venv\Scripts\python.exe code\inspect_inputs.py
.venv\Scripts\python.exe code\cache_bert_features.py
.venv\Scripts\python.exe code\problem1_extract.py
```

```
.venv\Scripts\python.exe code\problem2_train.py --variant robust
.venv\Scripts\python.exe code\problem2_train.py --variant no_aug
.venv\Scripts\python.exe code\problem3_explain.py
.venv\Scripts\python.exe code\analyze_results.py
.venv\Scripts\python.exe code\make_figures.py
.venv\Scripts\python.exe code\generate_latex_tables.py
latexmk -xelatex -interaction=nonstopmode main.tex
```

若检查点已经存在而只修改了经审计的确定性后处理，可运行 `refresh_fixed_model_outputs.py`，该脚本不训练、不选模。BERT 原始权重不打包进提交附件，脚本以模型名和缓存提交号下载；训练数据也不重复打包。

A.4 逐问约束复核

表 A.2 逐问约束复核

问题	样本与字段	标签规则	时间映射与适用约束
一	100 个视频、转写、标签	原连续强度及正/中/负	保存秒数、帧号；100 条不追加到问题二
二	3395/728/727 及附件 3 的 30 条；三模态	$< 0, = 0, > 0 \mapsto 0, 1, 2$	局部缺失、填充分开；附件 3 无真值
三	附件 4 的 20 条；三模态与原视频	沿用问题二固定规则	关键文字、语音段、帧均回溯；不报告真实准确率